GUIA DE ESTUDO: PROVA PRÁTICA DE MACHINE LEARNING

A prova focará na sua capacidade de interpretar dados, escolher o modelo correto e manipular texto para NLP.

Parte 1: Fundamentos Teóricos

Para as questões teóricas, você deve ser capaz de explicar a lógica por trás das escolhas técnicas:

1.1 Classificação vs. Regressão

- Classificação: Usada quando o objetivo é prever uma categoria (Ex: "É Spam?", "Qual a intenção do cliente?", "É Bot ou Humano?").
- Regressão: Usada quando o objetivo é prever um valor numérico contínuo (Ex: "Quanto tempo de espera?", "Qual o custo do lead?").

1.2 Métricas de Erro

- MAE (Mean Absolute Error): Média simples do erro. Ótimo para entender o impacto financeiro ou temporal direto.
- RMSE (Root Mean Squared Error): Penaliza erros grandes. Se o RMSE é muito maior que o MAE, o modelo está cometendo erros "grosseiros" (outliers).

1.3 O Pipeline de NLP

Saiba explicar a ordem e a função de cada etapa:

1. Normalização: .lower() (padronização).
2. Limpeza: Remoção de pontuação e caracteres especiais.
3. Tokenização: Quebrar a frase em palavras individuais.
4. Stopwords: Remover palavras que não trazem sentido (artigos, preposições).

Parte 2: Guia de implementação

Revise as principais funções que você precisará utilizar no ambiente de prova:

2.1 Manipulação de Dados (Pandas)

```
import pandas as pd

df = pd.read_csv('arquivo.csv')
```

```
print(df.head())          # Ver as primeiras linhas
print(df.describe())      # Estatística descritiva (Média, Mediana, DP)
X = df[['coluna1', 'col2']] # Seleção de entradas
y = df['alvo']            # Seleção da resposta
```

2.2 Modelagem (Scikit-Learn)

```
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.linear_model import LinearRegression

# Divisão Treino/Teste
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2)

# Escolha do Modelo
modelo = DecisionTreeClassifier() # Para Categorias
# ou
modelo = LinearRegression()       # Para Números

# Treino e Predição
modelo.fit(X_train, y_train)
previsoes = modelo.predict(X_test)
```

2.3 Processamento de Texto (NLP)

```
import string
from nltk.tokenize import word_tokenize
from nltk.corpus import stopwords
# Limpeza Básica
texto = "Olá, Mundo!!!"
texto_limpo = texto.lower().translate(str.maketrans('', '', string.punctuation))
tokens = word_tokenize(texto_limpo)
stops = set(stopwords.words('portuguese'))
tokens_finais = [t for t in tokens if t not in stops]
```

Check-list para treino da prova:

Para a prova, tente realizar estas tarefas sem consultar o código completo:

1. Carregar um CSV e calcular a Mediana e o Desvio Padrão de uma coluna.
2. Explicar por que o RMSE aumentou após você injetar um erro absurdo nos dados.
3. Criar um script que limpa uma frase, removendo pontuação e as palavras "o", "a", "de".
4. Diferenciar quando usar uma Árvore de Decisão ou uma Regressão Linear.